

HAMILTON FONTE II

**DIZANG: UMA SOLUÇÃO PARA COLETA DE
EVIDÊNCIAS FORENSES PARA ATAQUES DE
INJEÇÃO NA NUVEM**

Documento apresentado à Escola Politécnica
da Universidade de São Paulo para a realiza-
ção do Exame de Qualificação de Mestrado
em Engenharia Elétrica.

São Paulo
2017

HAMILTON FONTE II

**DIZANG: UMA SOLUÇÃO PARA COLETA DE
EVIDÊNCIAS FORENSES PARA ATAQUES DE
INJEÇÃO NA NUVEM**

Documento apresentado à Escola Politécnica
da Universidade de São Paulo para a realiza-
ção do Exame de Qualificação de Mestrado
em Engenharia Elétrica.

Área de concentração:
Engenharia da Computação

Orientador:
Marcos Antonio Simplicio Junior

São Paulo
2017

RESUMO

A adoção de arquiteturas em nuvem aumenta a cada dia, e com ela também o número de casos em que esse tipo de tecnologia é usada para fins ilícitos. No ano de 2015 o número de registros de atas notariais comprovando abusos e crimes virtuais cresceu 87%. Infelizmente, devido à natureza volátil da nuvem, a tarefa de coletar evidências para análise forense nesse ambiente tem esbarrado em desafios práticos e legais. A prática herdada da forense tradicional para coleta de evidências, onde se isola e cena do crime e coleta-se todas as evidências, foi traduzida para a forense digital como a cópia bit a bit da mídia que se deseja investigar. Tal prática levou a coleta de grandes volumes de informação para análise impactando o tempo de investigação. Duas características das soluções em nuvem têm dificultado a obtenção de evidências válidas. O compartilhamento de recursos físicos entre vários usuários impede a remoção dos mesmos para análise uma vez que isso viola a privacidade de elementos não envolvidos na investigação. A localização do recurso físico em uma região geográfica diferente de onde o crime foi cometido pode impedir a coleta de evidências caso não haja acordos de cooperação estabelecidos. Estes aspectos, se não forem levados em consideração, podem por em xeque a credibilidade da evidência. Este trabalho analisa propostas na literatura voltadas a resolver os principais desafios existentes na coleta de evidências na nuvem, discutindo suas limitações, e então propõe uma solução que cobre coleta, transporte e armazenamento da evidência visando suplantá-las. A solução aqui proposta provê uma forma de correlacionar evidências e sua origem virtual, permitindo transportar e armazenar tais dados sem afetar sua credibilidade. Para tal faremos uso de contêiners e seu identificador para relacionar a evidência a sua origem, tal técnica tem a vantagem que conseguir preservar a relação evidência - origem mesmo que esta última não exista mais na solução sob investigação. Especificamente, ela tem como focos (1) a reprodutibilidade do processo de coleta, (2) não violar jurisdição e (3) não violar a privacidade dos não envolvidos na investigação. **MARCOS: Discuta como é feito e quais os benefícios da solução. Não seja tão sintético: não há limitação de espaço aqui! Até no artigo tem mais texto... Hamilton - Acho que foi**

ABSTRACT

The adoption of cloud architectures increases every day and with it, also the number of cases where such technology is used for illicit purposes. In 2015, the number of notarial records acts related digital abuses and virtual crimes grew by 87%. Unfortunately, due to the volatile nature of the cloud, the task of collecting evidences for forensic analysis frequently run into practical and legal issues. The practice, inherited from the traditional forensics, to isolate the crime scene and collect all evidences, has been translated to digital forensic as the bitwise copy of the media to be investigated. Although efficient, this practice led to the collection of large volumes of information for analysis which in its turn impacted investigation time. On top of that, two other features of cloud solutions have made it difficult to obtain valid evidence. The sharing of physical resources among multiple users which prevents the removal of hardware for analysis as this violates the privacy of parties not involved in the investigation. The physical resource geographic location which, if located in a country different from where the crime was committed, may prevent the collection of evidence if established cooperation agreements are not in place. These aspects, if not taken into account, may call into question the credibility of the evidence in a court of law. This work analyzes other proposals aimed at solving the main challenges of collecting forensic evidence in the cloud, discusses their limitations and then proposes a solution that covers collection, transport and storage of evidence in order to overcome them. This proposal provides a way of correlating evidence and its virtual origin, transport and store such data without affecting its credibility. For this we make use of Linux Container and its identifier to relate the evidence to its origin. Such a technique has the advantage that it can preserve the relation evidence - origin even though the origin doesn't exists anymore. It focus on (1) the reproductibility of the collection process, (2) the non violation of juristiction, and (3) the non violation of privacy of those not involved in the investigation.

LIST OF FIGURES

| | | |
|---|--|----|
| 1 | Automated Forensics Data Acquisition Model | 20 |
| 2 | Virtuoso | 21 |
| 3 | A Log Based Approach Model | 22 |
| 4 | Backup Approach Model | 23 |
| 5 | FROST | 24 |
| 6 | Digital Forensic Framework for Cloud Environment | 25 |
| 7 | Digital FaaS - Indexed Data | 26 |
| 8 | Cronograma de projeto | 32 |

LIST OF TABLES

| | | |
|---|--|----|
| 1 | Comparativo de soluções de coleta de informações de memória de máquinas em nuvem para análise forense | 30 |
|---|--|----|

LIST OF ABBREVIATIONS AND ACRONYMS

| | |
|-------|--|
| VM | <i>Virtual Machines</i> - Máquina Virtual |
| SO | Sistema Operacional |
| SaaS | <i>Software as a Service</i> - Programa como serviço |
| PaaS | <i>Platform as a Service</i> - Plataforma como serviço |
| IaaS | <i>Infrastructure as a Service</i> - Infra-estrutura como serviço |
| FaaS | <i>Forensics as a Serviço</i> - Forense como serviço |
| LXC | <i>Linux Containers</i> - Contêiners Linux |
| VMI | <i>Virtual Machine Introspection</i> - Introspecção da máquina virtual |
| VMM | <i>Virtual Machine Manager</i> - Gerenciador de máquinas virtuais |
| CSP | <i>Cloud Service Provider</i> - Provedor de serviços de nuvem |
| GRR | <i>Google Rapid Response</i> |
| FROST | <i>FoRensic Open Stack Tools</i> |
| API | <i>Aplication Programing Interface</i> - Interface Programática de Aplicação |
| SWGDE | <i>Scientific Working Group on Digital Evidence</i> - Grupo de Trabalho Científico sobre Evidência Digital |
| ETL | <i>Extract, Transform and Load</i> - Extrair, transformar e carregar |

CONTENTS

| | | |
|----------|---|-----------|
| 1 | Introdução | 9 |
| 1.1 | Objetivos | 10 |
| 1.2 | Justificativa | 11 |
| 1.3 | Organização do documento | 12 |
| 2 | Fundamentação Teórica | 13 |
| 2.1 | Nuvem computacional | 13 |
| 2.2 | Uso de contêiners | 14 |
| 2.3 | Forense digital e seus desafios | 15 |
| 2.3.1 | Aceitabilidade da evidência em processo legal. | 16 |
| 2.3.2 | Volume de dados para coleta | 17 |
| 2.3.3 | Privacidade e jurisdição | 17 |
| 2.3.4 | Coleta de evidências de memória volátil de máquinas em nuvem | 18 |
| 3 | Revisão da literatura | 19 |
| 3.1 | Acessar e coletar as informações de memória das máquinas virtuais em nuvem | 26 |
| 3.2 | Capacidade de reproduzir o processo e obter os mesmos resultados . . | 27 |
| 3.3 | Não violar privacidade ou jurisdição das partes não envolvidas na in- vestigação | 28 |

| | | |
|----------|---|-----------|
| 3.4 | Garantir a cadeia de custódia da evidência | 29 |
| 3.5 | Resumo | 29 |
| 4 | Proposta de projeto | 31 |
| 4.1 | O que foi feito e cronograma esperado para os próximos passos | 31 |
| 4.2 | Limitações | 32 |
| 4.3 | Contribuições | 33 |
| | References | 34 |

1 INTRODUÇÃO

MARCOS: Erro comum 31: não coloque seção ou sub-seção sem texto no capítulo seção - Hamilton: Feito, falta de atenção minha

Técnicas de virtualização, replicação de serviços e compartilhamento de recursos entre múltiplos usuários (multi-inquilinato) proveem a nuvens computacionais uma elevada escalabilidade (MORSY; GRUNDY; MULLER, 2010). Ao mesmo tempo, tais mecanismos também criam grande volatilidade dos recursos virtuais que executam aplicações em nuvem. Afinal, quando submetida a uma carga elevada, uma aplicação hospedada na nuvem pode criar clones das máquinas virtuais (*virtual machines* – VM) que a hospedam e balancear a carga entre elas, de modo a atender à demanda sem prejuízos na qualidade do serviço oferecido. Após esse pico, as máquinas que foram clonadas são normalmente desativadas, seus recursos liberados e o sistema retorna à capacidade anterior, evitando-se custos desnecessários.

Embora interessante do ponto de vista de eficiência e custos, do ponto de vista forense a volatilidade da nuvem traz problemas em caso de ataques. Por exemplo, caso uma das instâncias de processamento virtuais criadas temporariamente seja alvo de ameaças que atuam diretamente na sua memória, sem deixar rastros em discos (e.g., arquivos de *log*), as evidências desse evento podem ser completamente perdidas após elas serem desativadas e terem seus recursos liberados. Essa dificuldade é ainda agravada por aspectos como multi-inquilinato e multi-jurisdição típicas de soluções em nuvem (GILBERT; SUJEET, 2008). Especificamente, o aspecto multi-inquilino

dificulta a obtenção do *hardware* que executa as aplicações de interesse, pois, como ele é compartilhado por vários usuários, removê-los para análise poderia levar a uma violação de privacidade dos usuários não relacionados à investigação. Já a natureza distribuída da nuvem pode levar à alocação de informações relevantes à investigação em vários países, dificultando a obtenção das mesmas em especial quando não existem acordos de cooperação entre as entidades envolvidas (DYKSTRA; SHERMAN, 2012). Combinadas, tais características dificultam a coleta de evidências com a credibilidade necessária para que elas possam ser usadas em processos legais, o que exige o respeito à privacidade, à jurisdição e à cadeia de custódia, bem como a reprodutibilidade do processo de coleta (RAHMAN; KHAN, 2015).

Embora existam soluções na literatura que abordam a coleta de informações de nuvem com o propósito de análise forense, a grande maioria delas aborda a coleta, o transporte e o armazenamento de forma isolada. Por exemplo, trabalhos como (DYKSTRA; SHERMAN, 2013) e (REICHERT; RICHARDS; YOSHIGOE, 2015) tratam de fatores como multi-inquilinato e multi-jurisdição, discutindo formas de coleta e preservação da evidência fora da nuvem. Já estudos como (GEORGE; VENTER; THOMAS, 2012) se concentram na análise forense para a coleta de evidência de máquinas virtuais enquanto elas estão em execução, enquanto trabalhos como (SANG, 2013) abordam a questão de processos de garantia de cadeia de custódia em ambientes de nuvem para transporte da evidência. Por outro lado, não foram identificadas na literatura propostas que (1) descrevam como o dado é coletado e armazenado observando a cadeia de custódia, e (2) visem garantir que, mesmo que um recurso virtualizado (e.g., uma VM) seja desalocada, haja condições de se reproduzir o processo de coleta de evidências.

1.1 Objetivos

O presente trabalho visa suplantiar as limitações supracitadas, melhorando a capacidade de coleta de evidências de aplicações em nuvem. Mais precisamente, isso é

por meio de uma proposta que tem como focos (1) a reprodutibilidade do processo de coleta, (2) o estabelecimento de vínculo entre a evidência coletada e sua origem, (3) a preservação da jurisdição e da privacidade dos não envolvidos na investigação e (4) a garantia de custódia da evidência. Em suma, a solução descrita provê uma forma de correlacionar evidências e sua origem virtual, permitindo transportar e armazenar tais dados de modo a preservar sua credibilidade. Para isso, a proposta supõe que o sistema sendo monitorado é executado dentro de um contêiner em nuvem.

1.2 Justificativa

Uma nuvem computacional é um modelo de infraestrutura no qual recursos compartilhados em quantidade configurável, acessíveis via rede, são alocados e desalocados com esforço mínimo de gerenciamento por parte de um provedor de serviços (MELL; GRANCE, 2011). Há três modelos principais de comercialização de uso da nuvem (MELL; GRANCE, 2011): *software* como serviço (*Software as a Service* – SaaS), na qual se provê o *software* que será usado pelo cliente; plataforma como serviço (*Platform as a Service* – PaaS), na qual se provê o ambiente para que o cliente desenvolva, teste e execute seu *software*; e, o tipo mais pertinente para este trabalho, Infraestrutura como serviço (*Infrastructure as a Service* – IaaS), na qual são fornecidos recursos computacionais básicos, como processamento e memória, em geral de forma virtualizada.

Virtualização tem sido amplamente adotada por empresas das mais diversas áreas. Segundo o "State of the Cloud Report" realizado pela empresa Right Scale, 95% das organizações entrevistadas estão utilizando ou experimentando soluções em nuvem no modelo IaaS (Right Scale, 2017). A virtualização de recursos na nuvem, embora tradicionalmente feita por meio de máquinas virtuais, vêm sendo crescentemente feita também na forma de contêineres. De fato, segundo o "Container Market Adoption Survey 2016", realizado pelas empresas DevOps.com (<https://devops.com/>) e ClusterHQ

(<https://clusterhq.com>) com 235 empresas que têm desenvolvimento de software como sua atividade fim ou como suporte à atividade fim, 76% dos respondentes utilizam contêineres para melhorar a eficiência do processo de desenvolvimento e em suas arquiteturas de micro-serviços em nuvem.

O crescente volume de informações que as soluções em nuvem armazenam e trafegam hoje e os aspectos o multi-inquilino e a multi-jurisdição dos provedores de infraestrutura em nuvem estão entre os principais obstáculos enfrentados pelos investigadores forenses. (QUICK; CHOO, 2014) (GILBERT; SUJEET, 2008)

1.3 Organização do documento

O restante deste documento está organizado nos seguintes capítulos.

O Capítulo 2 apresenta o ambiente em que este trabalho está inserido, as tecnologias envolvidas e os desafios a serem superados. O Capítulo 3 analisa os trabalhos relacionados a forense de memória em nuvem. O Capítulo 4 apresenta uma proposta para conclusão deste trabalho.

MARCOS: liste todos os capitulos e diga o que eles discutem. O cap. 1 não precisa (o leitor já leu...) - Hamilton: Feito lista de capítulos e criação de labels para os mesmos

2 FUNDAMENTAÇÃO TEÓRICA

Desde 2001, modelos de como uma investigação forense digital deve ser conduzida foram propostas. O *Enhanced Digital Investigation Model* proposto por Carrier e Stafford em 2003 foi a última iteração na evolução do processo forense digital. Entretanto tais modelos de investigação foram desenvolvidos antes da aparição de tecnologias de computação em nuvem e partem do princípio que o investigador tem acesso e controle sobre o sistema sob investigação. (GRISPOS; STORER; GLISSON, 2012) Esta defasagem está no centro dos desafios da forense digital.

2.1 Nuvem computacional

Uma nuvem computacional é um modelo de infraestrutura no qual recursos compartilhados em quantidade configurável, acessíveis via rede, são alocados e desalocados com esforço mínimo de gerenciamento por parte de um provedor de serviços. Há três modelos principais de comercialização de uso da nuvem: *software* como serviço (*Software as a Service* – SaaS), na qual se provê o *software* que será usado pelo cliente; plataforma como serviço (*Platform as a Service* – PaaS), na qual se provê o ambiente para que o cliente desenvolva, teste e execute seu *software*; e, o tipo mais pertinente para este trabalho, Infraestrutura como serviço (*Infrastructure as a Service* – IaaS), na qual são fornecidos recursos computacionais básicos, como processamento e memória, em geral de forma virtualizada (MELL; GRANCE, 2011). Uma arquitetura usada hoje nas soluções em nuvem são as auto-escaláveis onde recursos são altamente voláteis

com recursos sendo alocados e desalocados a qualquer momento. Estas implementações tem a vantagem de usar os recursos de nuvem de uma forma mais eficiente e menos necessidade de intervenção humana.

2.2 Uso de contêiners

Segundo (AMAZON, 2016), container é um método de virtualização do sistema operacional que permite executar uma aplicação e suas dependências em um processo com os recursos como disco, memória e rede isolados. Diferentemente de máquinas virtuais, a virtualização com contêineres é feita no nível do SO nativo, tem uma implementação mais simples eliminando camadas entre o aplicativo executado e o *hardware* físico permitindo maior granularidade no controle sobre esses recursos melhorando a eficiência da infraestrutura. Uma tecnologia bastante utilizada para esse propósito são Contêineres Linux (LXC) (LINUXCONTAINERS.ORG, 2015), que aproveitam-se de funcionalidades como *cgroups*, *kernel namespaces* e *chroot* do kernel do Linux para auxiliar no gerenciamento e isolamento de recursos virtuais.

Control Groups (*cgroups*) é uma funcionalidade do Kernel do Linux que limita e isola o uso de recursos como CPU, memória e disco de um conjunto de processos e os organiza de forma hierárquica. O trabalho nesta funcionalidade começou em 2006 na Google sob a denominação de *contêiner de processos*. No fim de 2007 seu nome mudou para *control groups* e foi adicionado a versão 2.6.24 do kernel lançado em 2008 (Unix Man Pages, a).

Namespacing é uma funcionalidade do Kernel do Linux usado para isolar e virtualizar recursos do sistema operacional como Ids de processos, acessos a rede, comunicação inter-processos e sistema de arquivos. *Namespacing* envolve os recursos do sistema operacional em uma abstração que faz parecer aos processos de um mesmo namespace que eles tem sua própria instância isolada de um recurso global, é a princi-

pal funcionalidade por trás da implementação de contêineres (Unix Man Pages, d).

Change Root (*chroot*) é uma funcionalidade do Kernel do Linux usado para mudar o diretório root do processo que está chamando a função e de todos os seus processos filhos. A chamada a *chroot* altera o processo de resolução de caminhos do sistema operacional para o processo que o chamou (Unix Man Pages, b). Desta forma pode-se instalar uma distribuição Linux secundária em uma pasta, ao invés de uma partição, e executar programas desta pasta sem perda significativa de desempenho.

2.3 Forense digital e seus desafios

Forense digital (tambem conhecida por forense computacional) é um conjunto de técnicas de coleta e análise da interação entre humanos e computadores de forma que esta seja aceita em um processo legal. Tal como a forense tradicional, a forense digital se baseia no princípio de Locard. Definido pelo médico francês Edmond Locard, o princípio de Locard estabelece que “Quando um indivíduo entra em contato com outro objeto ou indivíduo, este sempre deixa vestígio deste contato” (RAMOS, 2011).

A forense digital quando aplicada a investigação de incidentes em soluções na nuvem enfrenta desafios adicionais relacionados a coleta, transporte e análise da evidência. A primeira delas diz respeito a aceitabilidade de uma evidência. Para que uma evidência seja aceita em um processo legal é necessária que a cadeia de custódia relacionada a evidência tenha sido garantida. Cadeia de custódia é o processo de documentação da história cronológica da evidência de modo a saber onde a evidência esteve e quem teve acesso a ela (RAMOS, 2011). O SENASP 2013 diz que: “CADEIA DE CUSTÓDIA: sistemática de procedimentos que visa à preservação do valor probatório da prova pericial caracterizada.” Assim a Forense digital tem por objetivo a investigação de evidências digitais da interação entre homem e máquina de modo a reconstruir a cadeia de eventos no passado de forma que suas conclusões sejam validadas

por terceiros.

2.3.1 Aceitabilidade da evidência em processo legal.

O processo de análise forense no evento de um crime digital é descrito no EDIPM - *Enhanced Digital Investigation Process Model* por 4 fases: Identificar, preservar, examinar, apresentar. (GRISPOS; STORER; GLISSON, 2012) Na fase de preservação da evidência deve ser feita de forma que os autores descrevem como “forensicamente aceitável” isto é, coletar as evidências de forma que as mesmas sejam aceitas em um processo legal e não sejam invalidadas durante o processo. Segundo (RAMOS, 2011) a aceitabilidade de uma evidência digital em um processo legal deve atender aos requisitos de *autenticidade*, processo pelo qual se pode garantir a autoria do documento eletrônico, ou seja, não permite dúvida quanto à identificação do autor e *integridade*, atestar a “inteireza do documento eletrônico após sua transmissão, bem como apontar eventual alteração irregular de seu conteúdo”. Caso haja dúvida sob qualquer um dos requisitos uma perícia técnica pode ser convocada, nesta será analisada o autor da evidência ou seja sua fonte e se a mesma não foi alterada no processo.

Em infra-estrutura física esta coleta era relativamente simples, bastava-se remover o recurso físico, transporta-lo para um laboratório e lá analisar a evidência. A Evidência era mantida em uma sala-cofre onde o acesso era controlado. A reprodutibilidade do processo de coleta e a manutenção da integridade da evidência eram tarefas bem diretas. A computação em nuvem, especialmente as de infraestrutura auto-escalável trouxeram um conjunto de desafios para se atingir este requisito. O recurso não pode mais ser removido pois o mesmo é utilizado por outros usuários não relacionados a investigação, fazê-lo constituiria violação de privacidade. A volatilidade dos recursos tornou a verificação do seu autor um processo mais complexo pois o recurso que a gerou pode não existir mais (SIMOU et al., 2014). A integridade da evidência também tornou-se mais complexa pois ela precisa ser coletada, transportada e armazenada. O

processo de cadeia de custódia ganhou grande visibilidade neste quesito. Violação de qualquer uma das características citadas anteriormente põe em dúvida a credibilidade da evidência.

2.3.2 Volume de dados para coleta

O processo de coleta da evidência na forense digital herdou suas práticas da forense tradicional onde isola-se cena do crime e coletam-se as evidências presentes. Transportando para a forense digital criou-se o hábito de se realizar cópia bit a bit da informação que se deseja analisar. No passado, com as soluções manipulando quantidades bem menores de memória, disco e tráfego, tal prática não trazia problemas. Nas atuais soluções, aplicações e arquiteturas em nuvem, o volume de dados aumentou consideravelmente. Em 2014 investigadores forenses tinham em média 6 meses de backlog para analisar (QUICK; CHOO, 2014). Em conversas informais com analistas forenses é comum a métrica de em média apenas 2% do material coletado ser útil a análise. Encontrar uma forma de armazenar menos informações de modo a tornar a fase de análise mais rápida e eficiente ajudará nas investigações.

2.3.3 Privacidade e jurisdição

Na metodologia tradicional de coleta de evidências para análise, isola-se o ambiente e as evidências são removidas. Transportando para a forense digital, temos a prática de remover o equipamento para realização de cópia bit a bit da evidência. Nas soluções de infra estrutura física esta prática não trás problemas, os objetos ou indivíduos sob investigação estão diretamente relacionados ao equipamento removido. Nas soluções em nuvem esta prática não pode mais ser utilizada, pois como o recurso físico é compartilhado por vários usuários não envolvidos na investigação, remove-los configura violação de privacidade. Um complicador a mais é o fato de os dados não estarem armazenados no mesmo território em que a investigação é realizada deman-

dando acordos de cooperação jurídica entre as partes o que nem sempre é possível (SIMOU et al., 2014). Neste cenário encontrar uma forma de coletar a evidência sem violar jurisdição e privacidade são de grande importância num futuro próximo.

2.3.4 Coleta de evidências de memória volátil de máquinas em nuvem

Na metodologia tradicional de coleta de evidências para análise isola-se o ambiente e as evidências são removidas. Transportado para a forense digital temos a prática de remover o equipamento para realização de cópia bit a bit da evidência. Nas soluções de infra estrutura física esta prática não trás problemas, os objeto ou indivíduos sob investigação estão diretamente relacionados ao equipamento removido. Nas soluções em nuvem esta prática não pode mais ser utilizada pois como o recurso físico é compartilhado por vários usuários não envolvidos na investigação, remove-los configura violação de privacidade. Um complicador a mais é o fato de os dados não estarem armazenados no mesmo território em que a investigação é realizada demandando acordos de cooperação jurídica entre as partes o que nem sempre é possível. Neste cenário encontrar uma forma de coletar a evidência sem violar jurisdição e privacidade são de grande importância num futuro próximo.

3 REVISÃO DA LITERATURA

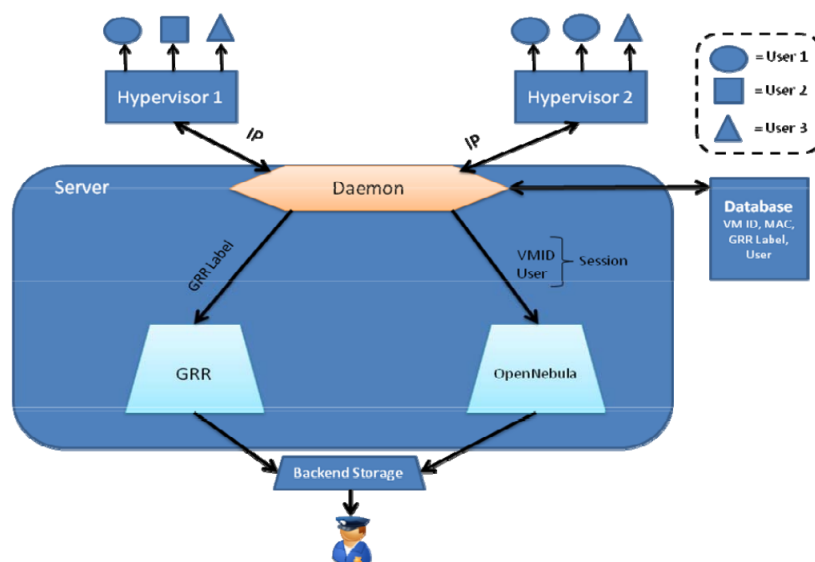
MARCOS: Explique melhor as soluções: você tem espaço, então pode deixar este capítulo muito mais auto-contido

Os principais aspectos relacionados a coleta de evidências para análise forense em nuvem são, coleta, transporte, armazenamento, garantia da cadeia de custódia e reprodutibilidade do processo de coleta. Das propostas encontradas em literatura 6 foram selecionadas como melhor representação do estado da arte, a seguir uma breve descrição de cada uma delas.

O modelo proposto por (REICHERT; RICHARDS; YOSHIGOE, 2015) é um processo de coleta de evidências integrado ao *hypervisor* e disparado por algum sistema de detecção de intrusão. A partir do momento em que uma ameaça é detectada, o modelo tira instantâneos das máquinas virtuais comprometidas. O modelo toma cuidado para excluir informações de clientes não relacionados a investigação e armazena o restante em local seguro, tudo de forma automatizada. O autor não descreve os detalhes do armazenamento mas diz que é “forensicamente aceitável”. O modelo faz uso de GRR para agregar e analisar as evidências coletadas. O modelo possui um motor de regras que se baseia em um conjunto de descrições de ameaças conhecidas armazenadas em banco para, caso alguma evidência coletada coincida com ameaças armazenadas, ele alerta um usuário humano para uma avaliação mais detalhada. O intervalo de tempo em que os instantâneos de memória são gerados é configurável e são todos armazenados em persistência. Este modelo tem como principal vantagem a automação do processo

de coleta, sem intervenção humana é mais fácil garantir a cadeia de custódia. A figura 1 mostra o desenho da arquitetura proposta pelo autor.

Figure 1: Automated Forensics Data Acquisition Model



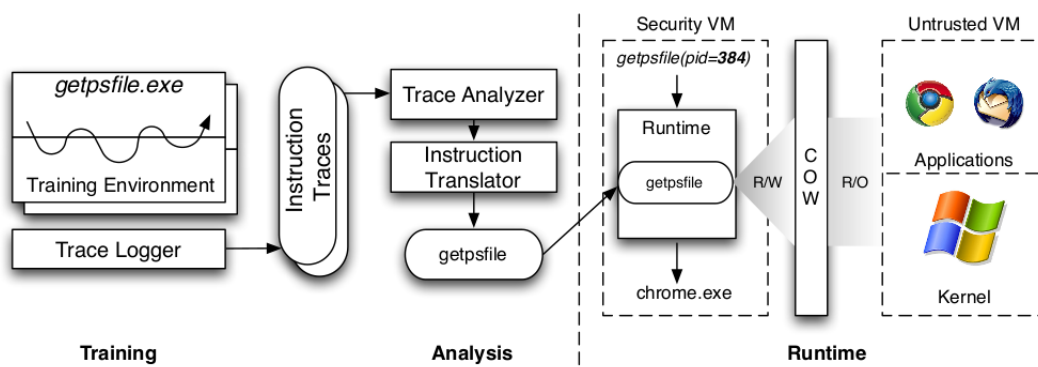
Fonte: (REICHERT; RICHARDS; YOSHIGOE, 2015)

A proposta de (POISEL; MALZER; TJOA, 2013) é baseada na técnica de introspecção em máquina virtual (VMI) para coleta de memória volátil. Esta técnica se apoia na necessidade do gerenciador de máquinas virtuais (VMM) em mapear recursos físicos da máquina hospedeira a recursos alocados à máquina virtual cliente. Este mapeamento é usado para permitir que a memória volátil copiada da máquina virtual seja reconstruída em uma máquina física para realização da análise. A proposta utiliza de coleta contínua dos instantâneos de memória durante o funcionamento do sistema sem distinção do que aconteceu antes ou depois do fato de interesse e todos os instantâneos de memória são armazenados para posterior análise. Para eliminar a chance de inconsistências no instantâneo de memória volátil, a máquina virtual tem sua execução suspensa durante o processo de extração. Uma desvantagem da técnica de VMI mencionado pelo próprio autor é a necessidade de tradução de endereços de memória da máquina virtual em endereços de memória da máquina física hospedeira. Esta tradução depende de conhecimento do que está sendo executado na máquina virtual, logo uma

solução baseada em VMI não é completamente portátil sendo necessário adequações para diferentes clientes além de ser computacionalmente custoso.

Também na vertente de introspecção de máquina virtual, (DOLAN-GAVITT et al., 2011) propõe o *Virtuoso*, um arcabouço de coleta de informações de processos específicos em uma máquina virtual. O arcabouço tem 3 fases, a primeira realiza um estudo em uma máquina virtual teste do processo que se deseja coletar dados de memória mapeando o conjunto de instruções executado. A fase 2 traduz o conjunto de instruções mapeados na fase 1 e cria um executável para que o processo seja executado fora da máquina virtual. A terceira fase usa um ambiente de execução na máquina hospedeira para rodar as instruções da fase 2. Este ambiente consegue acessar os endereços de memória da máquina virtual tornando possível coletar instantâneos de memória do processo em execução. A principal vantagem deste arcabouço é a capacidade de coletar instantâneos de memória de um processo específico. A figura 2 mostra um esquema do funcionamento do arcabouço

Figure 2: Virtuoso

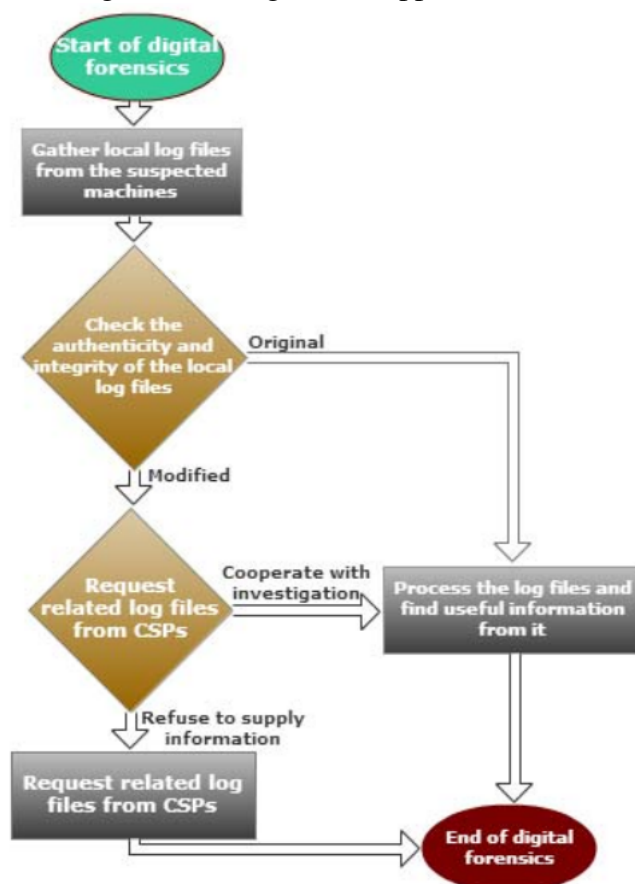


Fonte: (DOLAN-GAVITT et al., 2011)

O arcabouço proposto por (SANG, 2013) é um sistema que funciona em parceria com o provedor de nuvem onde este último envia informações ao arcabouço que os armazena em um local centralizado. O conjunto de informações armazenadas é acordado antecipadamente com o provedor de nuvem e vão desde instantâneos de memória volátil até pacotes trafegados nas interfaces de rede da máquina virtual. O arcabouço

coleta informações continuamente e usa cálculo de hash das evidências enviadas pelo provedor de nuvem para garantir que as mesmas não foram alteradas durante o transporte. Assim como as propostas anteriores, esta também não faz distinção do que aconteceu antes ou depois do fato de interesse coletando constantemente informações da máquina virtual. O próprio autor menciona que o arcabouço tem a desvantagem de depender da cooperação do provedor de nuvem. Esta dependência é uma estratégia considerada fraca pela comunidade forense pois a prioridade do CSP é o de garantir a disponibilidade do serviço não o de coletar evidências (ALQAHTANY et al., 2015). A figura 3 mostra um esquema do funcionamento da solução focada em um caso específico de log de rede como proposta pelo autor.

Figure 3: A Log Based Approach Model

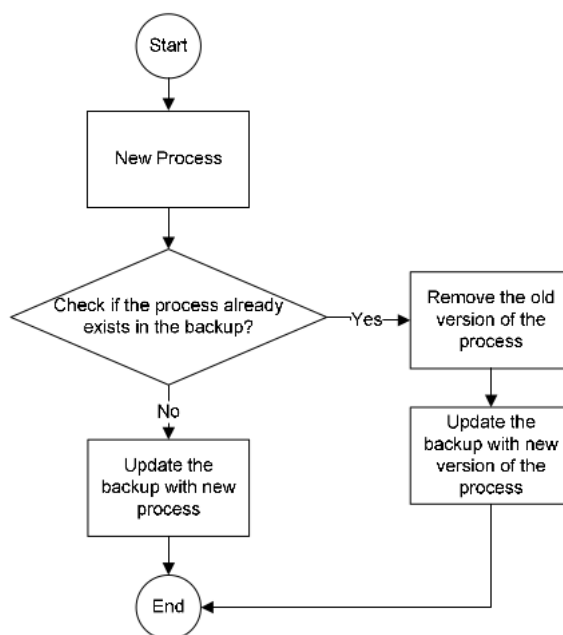


Fonte: (SANG, 2013)

O trabalho descrito em (DEZFOULI et al., 2012) é voltada a dispositivos móveis

e tem como principal vantagem a preocupação com as limitações de armazenamento do dispositivo. O processo de coleta do instantâneo de memória volátil do dispositivo separa as informações e as armazena por processo ativo, o autor usa esta técnica para melhor gerenciar o espaço que as informações estão ocupando em disco. Possui inteligência para descartar informações de processos que foram terminados e removidos da memória assim como inteligência para fazer uso ótimo do espaço de armazenamento do device. O processo de coleta de informações de memória volátil é feita continuamente independente de eventos de interesse como detecção de ameaças. A figura 4 o autor mostra um esquema macro de como o armazenamento da evidência é gerenciado.

Figure 4: Backup Approach Model

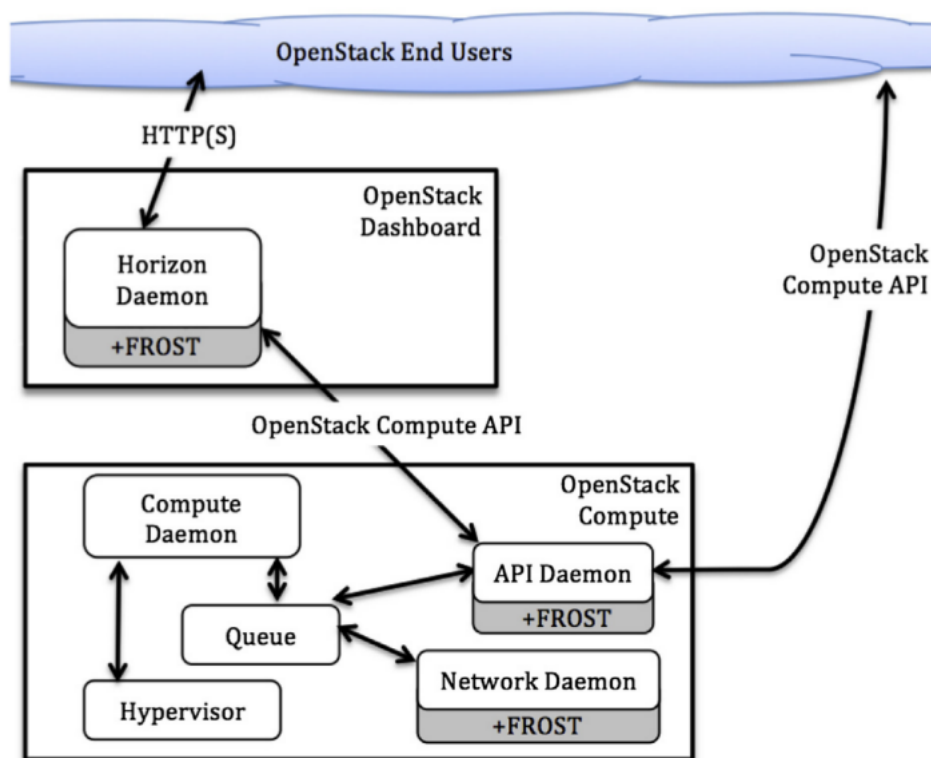


Fonte: (DEZFOULI et al., 2012)

A ferramenta FROST proposto por (DYKSTRA; SHERMAN, 2013) descreve um conjunto de bibliotecas integradas ao arcabouço *Open Stack Framework* de gerenciamento de infra estruturas virtualizadas. Através desta integração, FROST expõe um conjunto de API para serem usadas por aplicações de coleta de evidências forenses que dão acesso a recursos da máquina virtual sendo administrada como disco, logs

de tráfego de rede e memória volátil. A proposta descreve apenas o arcabouço, deixa a critério do usuário detalhes como periodicidade e tamanho da coleta assim como a forma de transporte da evidência e onde ela será armazenada. De todas as propostas descritas neste capítulo esta é a única que demonstra preocupação com adequação a questões legais e padrões já estabelecidos na indústria forense. O autor declara que FROST segue as práticas definidas no Grupo de Trabalho Sobre Evidência Digital (SWGDE) e do Manual de Busca em Apreensão do Departamento de Justiça Norte-Americano. A figura 5 o autor mostra um esquema macro da integração entre FROST e o arcabouço *Open Stack Framework*

Figure 5: FROST

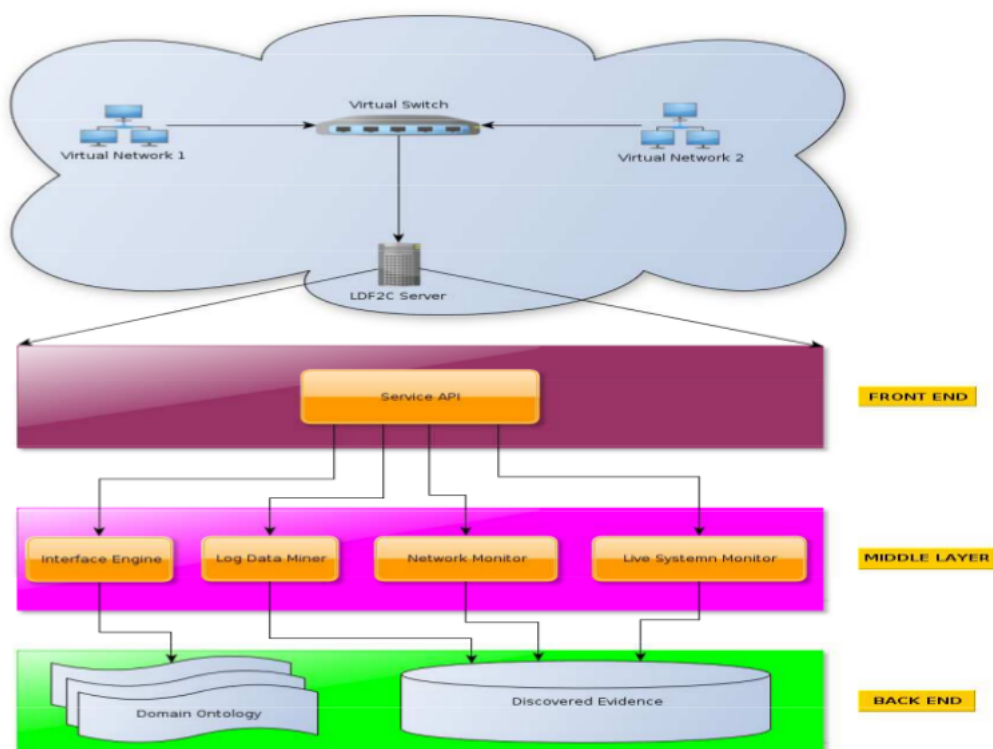


Fonte: (DYKSTRA; SHERMAN, 2013)

O trabalho descrito em (GEORGE; VENTER; THOMAS, 2012) está focado em monitoração de rede e opera em uma arquitetura de forense como serviço (FaaS). O autor propõe um conjunto de ferramentas que tem capacidade de realizar auto descoberta

das interfaces sob monitoração, coletar evidências de tais máquinas e armazená-las. O processo de auto descoberta e associação das evidências com usuários de rede é realizado por um motor baseado em ontologias armazenadas em um banco de dados próprio. Esta proposta foca apenas no processo de coleta. A descrição do armazenamento e transporte é superficial. Na figura 6 mostra o desenho da arquitetura proposta pelo autor.

Figure 6: Digital Forensic Framework for Cloud Environment

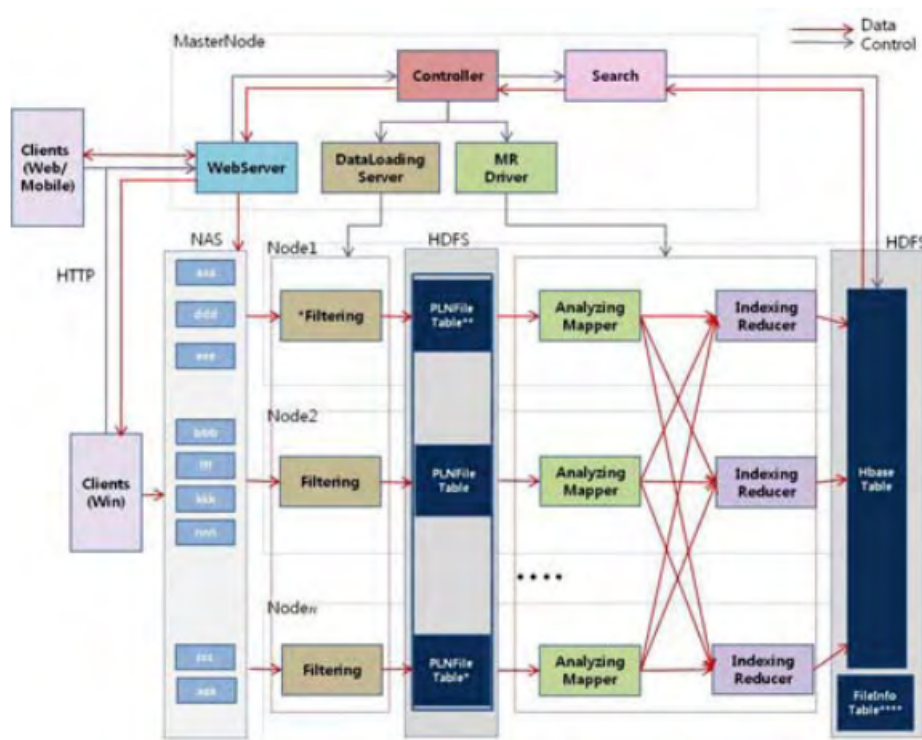


Fonte: (GEORGE; VENTER; THOMAS, 2012)

Na mesma vertente de forense como serviço, (LEE; UN, 2012) ataca o problema de grande volume de dados coletados propondo serviço de coleta e indexação de evidências. O serviço espera receber dados da execução do comando unix DD (Unix Man Pages, c) nas máquinas alvo onde, apoiado em processos ETL e MapReduce (WIKIPEDIA, 2018), esses dados serão disponibilizados para consulta pelos investigadores. A coleta ocorre continuamente a intervalos de tempo configuráveis. O autor não descreve onde os dados serão armazenados e quem será responsável pela infra-

estrutura de armazenamento. O autor também não fala como os dados serão transportados até o armazenamento e como ele garante que estes não foram alterados no processo. A figura 7 mostra o desenho da arquitetura do serviço proposta pelo autor

Figure 7: Digital FaaS - Indexed Data



Fonte: (LEE; UN, 2012)

A seguir os trabalhos mencionados acima são agrupados e avaliados com base nos diferentes aspectos que abordam.

3.1 Acessar e coletar as informações de memória das máquinas virtuais em nuvem

Diversos trabalhos de análise forense na nuvem se concentram na coleta de dados “após o fato”, ou seja, após a intrusão ser detectada (REICHERT; RICHARDS; YOSHIGOE, 2015; POISEL; MALZER; TJOA, 2013; DYKSTRA; SHERMAN, 2013; GEORGE; VENTER; THOMAS, 2012; SANG, 2013). Os processos de coleta

descritos nesses trabalhos podem ser iniciados de forma manual ou automaticamente, via integração com um mecanismo de detecção de intrusão. No caso específico de memória volátil, tal forma de coleta não consegue descrever como era a memória antes da intrusão, pois o processo só é acionado depois da detecção do ataque. Tal limitação pode trazer prejuízos à investigação, dado que algumas análises dependem exatamente da capacidade de se comparar dois momentos da memória (CASE et al., 2014). Entre os trabalhos estudados, a única proposta encontrada que leva tal necessidade em consideração é (DEZFOULI et al., 2012), que propõe que o dado seja armazenado no próprio equipamento sob análise. Infelizmente, entretanto, a aplicação de tal abordagem no cenário em nuvem é pouco viável, pois pode levar à perda de informações importantes caso a máquina virtual ou contêiner seja desativada, tendo seus recursos liberados.

Existem ainda trabalhos voltados à coleta de informações durante a execução do sistema, nos quais os dados são constantemente coletados sem distinção do que aconteceu antes ou depois do fato de interesse. Esse é o caso de trabalhos como (POISEL; MALZER; TJOA, 2013; DYKSTRA; SHERMAN, 2013; SANG, 2013; DOLAN-GAVITT et al., 2011), que adotam a estratégia de isolar e parar a máquina virtual para em seguida realizar o processo de coleta. Embora interessantes, as abordagens descritas nesses trabalhos podem levar a um elevado volume de dados coletados, além de também não tratarem o cenário em que é necessário coletar evidências quando os recursos virtuais contendo tais informações são liberados.

3.2 Capacidade de reproduzir o processo e obter os mesmos resultados

Se, durante uma análise forense, analistas diferentes obtêm resultados distintos ao executar o mesmo procedimento de coleta, a evidência gerada não tem credibilidade, inviabilizando seu uso em um processo legal. Por essa razão, a reprodutibilidade

do processo de coleta é uma parte importante da geração de evidências para análise forense. Infelizmente, entretanto, nenhuma das propostas encontradas na literatura atualmente permite tal reprodutibilidade em cenários de nuvem em que máquinas virtuais ou contêineres são desativados e seus recursos físicos liberados: todas elas dependem da existência do recurso virtual para a repetição do processo de coleta.

3.3 Não violar privacidade ou jurisdição das partes não envolvidas na investigação

Em um ambiente de nuvem pública, remover o *hardware* para análise posterior pode levar à violação de privacidade de usuários, uma vez que o multi-inquilinato desse cenário faz com que uma mesma máquina física guarde informações de diversos clientes, alguns dos quais podem não estar envolvidos na investigação em curso. Diversos trabalhos na literatura tratam esse problema adequadamente, por meio das duas estratégias principais: a primeira, adotada em (REICHERT; RICHARDS; YOSHIGOE, 2015; GEORGE; VENTER; THOMAS, 2012; POISEL; MALZER; TJOA, 2013; DYKSTRA; SHERMAN, 2013; LEE; UN, 2012), consiste em coletar dados pertinentes à investigação e armazená-los fora da nuvem; a segunda, empregada em (SANG, 2013) e que constitui um caso específico de (GEORGE; VENTER; THOMAS, 2012), depende da cooperação do provedor de serviços de nuvem para conseguir as informações necessárias à investigação. Dependendo do provedor de serviços de nuvem é uma estratégia pouco recomendada, entretanto, pois (1) o volume de dados de usuários pode forçar os provedores a limitar o tamanho dos *logs* armazenados, e (2) caso ocorra uma indisponibilidade causada por um ataque, o objetivo do provedor será o de restabelecer o serviço, não necessariamente o de preservar evidências (ALQAHTANY et al., 2015).

3.4 Garantir a cadeia de custódia da evidência

Dentre os trabalhos analisados, apenas (SANG, 2013) aborda a questão da garantia da cadeia de custódia. Especificamente, o trabalho emprega *hashes* para verificar a integridade da evidência, permitindo a detecção de alterações na mesma, embora não explique os mecanismos que poderiam ser utilizados para impedir acesso não autorizado (e, assim, potencial alteração) aos próprios hashes. As propostas dos outros autores concentram-se apenas no aspecto técnico da coleta, sem discutir claramente garantia de custódia mas apenas mencionando que as evidências devem ser coletadas de forma “forensicamente aceitável”.

3.5 Resumo

A Tabela 1 mostra um comparativo das soluções estudadas, considerando os aspectos discutidos nesta seção, posicionando as contribuições da proposta apresentada neste trabalho.

4 PROPOSTA DE PROJETO

A presente proposta está planejada para ser executada em 3 fases. A primeira fase tem por objetivo encontrar uma forma de relacionar a evidência coletada de um contêiner a sua origem de forma que o processo seja reproduzível. Para atingir este objetivo será implementado um protótipo de coleta de memória de uma máquina virtual executando contêiners em um notebook. A segunda fase tem por objetivo encontrar uma forma de transportar a evidência coletada a um local de armazenamento garantindo a cadeia de custódia. Para atingir este objetivo, será definida uma cadeia de custódia. De posse desta será realizada em uma nuvem computacional e envolverá o transporte da evidência para uma máquina física fora da nuvem. A terceira parte tem por objetivo a realização da análise de alguma vulnerabilidade utilizando-se do material coletado na primeira fase do projeto. As ações para se atingir este objetivo serão realizadas em um notebook com ferramental voltado a análise forense em memória.

4.1 O que foi feito e cronograma esperado para os próximos passos

Até então foram realizados com sucesso a duas primeiras partes do projeto.

Parte 1: A associação da evidência de memória coletada do contêiner de uma máquina virtual foi associada a sua origem através do *hash* de identificação da imagem do contêiner. O processo de coleta foi reproduzido com sucesso diversas vezes. Parte 2: O transporte da evidência para uma máquina física fora da nuvem utilizando camada

de transporte seguro a assinatura da mensagem.

Para o restante do projeto, que consiste da parte 3, espera-se seguir o cronograma descrito na figura 8 onde serão executadas as seguintes atividades.

- **Estudo das ferramentas de análise de memória:** Onde serão avaliadas ferramentas de análise de memória na busca por alguma que consiga decodificar as informações coletadas
- **Implementação / seleção de uma ferramenta de análise:** Nesta atividade será selecionada uma das ferramentas estudadas na atividade anterior. Caso nenhuma se mostre adequada, será implementada uma ferramenta para o propósito da fase 3
- **Realização de análises com a ferramenta escolhida / criada:** Nesta fase ocorrerá a tentativa de analisar um malware encontrado em alguma coleta realizada na fase 1

Figure 8: Cronograma de projeto

| Atividade / mês | 2018 | | | | | | | | | | | | 2019 | | | | | | | |
|--|------|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|------|-----|-----|-----|-----|-----|-----|-----|
| | jan | fev | mar | abr | mai | jun | jul | ago | set | out | nov | dez | jan | fev | mar | abr | mai | jun | jul | ago |
| Acompanhamento do estado da arte | | | | | | | | | | | | | | | | | | | | |
| Estudo das ferramentas de análise de memória | | | | | | | | | | | | | | | | | | | | |
| Implementação / seleção de uma ferramenta de análise | | | | | | | | | | | | | | | | | | | | |
| Realização de análises com a ferramenta escolhida / criada | | | | | | | | | | | | | | | | | | | | |
| Escrita e defesa de tese | | | | | | | | | | | | | | | | | | | | |

4.2 Limitações

Como a solução descrita tem como foco coletar informações de memória no espaço do usuário (*user space*), ela não consegue acessar o espaço de kernel (*kernel space*). Assim, Dizangem princípio não provê suporte a técnicas de investigação de malware que se baseiam em informações do *kernel space*, como, por exemplo, a comparação de informações do bloco do ambiente do processo (*Process Environment Block – PEB*),

que ficam no *user space*, com informações do descritor de endereços de memória virtual (*Virtual Address Descriptor – VAD*), que fica no *kernel space*. Análise de ameaças que realizam manipulação direta dos objetos do kernel (*D.K.O.M. – Direct Kernel Object Manipulation*) também não se beneficiam com a solução aqui proposta.

4.3 Contribuições

A contribuição esperada da presente proposta é o de demonstrar que é possível coletar evidências de uma infra-estrutura em nuvem de modo a atender os pré-requisitos de não violação de privacidade, não violação da jurisdição, reprodutibilidade do processo de coleta da evidência e garantia da cadeia de custódia. Demonstrar que é possível realizar a análise de evidência de memória com apenas a parte *user space* da memória coletada

REFERENCES

ALQAHTANY, S. et al. Cloud forensics: A review of challenges, solutions and open problems. In *Int. Conference on Cloud Computing (ICCC)*. [S.l.]: IEEE, 2015. p. 1–9.

AMAZON. *What are Containers*. 2016. Available from Internet: <https://aws.amazon.com/containers>.

CASE, A. et al. *The Art of Memory Forensics: Detecting malware and threats in Windows, Linux and Mac memory*. [S.l.]: Wiley, 2014.

DEZFOULI, F. et al. Volatile memory acquisition using backup for forensic investigation. In *Int. Conf. on Cyber Security, Cyber Warfare and Digital Forensic (CyberSec)*. [S.l.: s.n.], 2012. p. 186–189.

DOLAN-GAVITT, B. et al. Virtuoso: Narrowing the semantic gap in virtual machine introspection. In *IEEE Symposium on Security and Privacy*. [S.l.: s.n.], 2011. p. 297–312. ISSN 1081-6011.

DYKSTRA, J.; SHERMAN, A. Acquiring forensic evidence from infrastructure-as-a-service cloud computing: Exploring and evaluating tools, trust, and techniques. *Digital Investigation*, Elsevier Ltd, vol. 9, p. S90–S98, 2012. ISSN 17422876. (Proc. of the 12th Annual DFRWS Conference). Available from Internet: [dx.doi.org/10.1016/j.diin.2012.05.001](https://doi.org/10.1016/j.diin.2012.05.001).

DYKSTRA, J.; SHERMAN, A. T. Design and implementation of FROST: Digital forensic tools for the OpenStack cloud computing platform. *Digital Investigation*, Elsevier Ltd, vol. 10, p. S87–S95, 2013. ISSN 17422876. (Proc. of 13th Annual DFRWS Conference). Available from Internet: [dx.doi.org/10.1016/j.diin.2013.06.010](https://doi.org/10.1016/j.diin.2013.06.010).

GEORGE, S.; VENTER, H.; THOMAS, F. Digital Forensic Framework for a Cloud Environment. In *IST Africa*. Tanzania: IIMC, 2012. p. 1–8. ISBN 9781905824342.

GILBERT, P.; SUJEET, S. *Advances in Digital Forensics IV*. 1. ed. Orlando: Springer-US, 2008. vol. 1. ISSN 1098-6596. ISBN 9788578110796.

GRISPOS, G.; STORER, T.; GLISSON, W. Calm before the storm: the challenges of cloud computing in digital forensics. *International Journal of Digital Crime and Forensics*, vol. 4, no. 2, p. 28–48, 2012. ISSN 1466640073. Available from Internet: www.igi-global.com/article/calm-before-storm/68408.

LEE, J.; UN, S. Digital Forensics as a Service: A case study of forensic indexed search. p. 499–503, 2012.

LINUXCONTAINERS.ORG. *Linux Containers (LXC)*. 2015. Available from Internet: [<https://linuxcontainers.org/lxc/introduction/>](https://linuxcontainers.org/lxc/introduction/).

MELL, P.; GRANCE, T. *The NIST definition of cloud computing*. 2011. 7 p. NIST SP 800-145. csrc.nist.gov/publications/nistpubs/800-145/SP800-145.pdf. Available from Internet: www.mendeley.com/research/the-nist-definition-about-cloud-computing/.

MORSY, A. M.; GRUNDY, J.; MULLER, I. An Analysis of the Cloud Computing Security Problem. In *APSEC Cloud Workshop*. Sydney, Australia: [s.n.], 2010. Available from Internet: <https://arxiv.org/abs/1609.01107>.

POISEL, R.; MALZER, E.; TJOA, S. Evidence and cloud computing: The virtual machine introspection approach. *Journal of Wireless Mobile Networks, Ubiquitous Computing, and Dependable Applications*, vol. 4, no. 1, p. 135–152, 2013. ISSN 20935374 (ISSN). Available from Internet: citeseerx.ist.psu.edu/viewdoc/summary?doi=10.1.1.469.937.

QUICK, D.; CHOO, K. K. R. Impacts of increasing volume of digital forensic data: A survey and future research challenges. *Digital Investigation*, Elsevier Ltd, vol. 11, no. 4, p. 273–294, 2014. ISSN 17422876. Available from Internet: [dx.doi.org/10.1016/j.diin.2014.09.002](https://doi.org/10.1016/j.diin.2014.09.002).

RAHMAN, S.; KHAN, M. N. A. Review of live forensic analysis techniques. *International Journal of Hybrid Information Technology*, vol. 8, no. 2, p. 379–388, 2015. Available from Internet: www.sersc.org/journals/IJHIT/.

RAMOS, M. G. *Do Valor Probatório do Arquivo Digital*. PhD Thesis (PhD) — Universidade de Brasília, 2011.

REICHERT, Z.; RICHARDS, K.; YOSHIGOE, K. Automated forensic data acquisition in the cloud. *IEEE Int. Conf. on Mobile Ad Hoc and Sensor Systems*, p. 725–730, 2015.

Right Scale. *State of the Cloud Report*. 2017. www.rightscale.com/lp/state-of-the-cloud.

SANG, T. A log-based approach to make digital forensics easier on cloud computing. *Intelligent System Design and Engineering Applications (ISDEA)*, p. 91–94, 2013.

SIMOU, S. et al. Cloud forensics: Identifying the major issues and challenges. In *Advanced Information Systems Engineering (CAiSE 2014)*. [S.l.: s.n.], 2014. vol. 8484, p. 271–284. ISBN 9783319078809. ISSN 16113349.

Unix Man Pages. *cgroups - Control Groups*. <http://man7.org/linux/man-pages/man7/cgroups.7.html>.

_____. *chroot - Change Root command*. <http://man7.org/linux/man-pages/man1/chroot.1.html>.

_____. *dd - convert and copy a file*. <http://man7.org/linux/man-pages/man1/dd.1.html>.

_____. *Namespacing*. <http://man7.org/linux/man-pages/man7/namespaces.7.html>.

WIKIPEDIA. *MapReduce*. 2018. Available from Internet: <<https://en.wikipedia.org/wiki/MapReduce>>.